

# Applied Data Science Research

## A ZHAW Datalab perspective on the driver of digitization

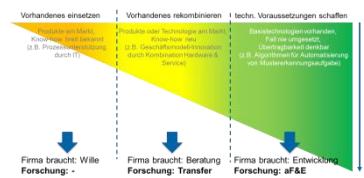


*Kick-off Phd Network in Data Science*  
Zürich, April 13, 2018

Thilo Stadelmann



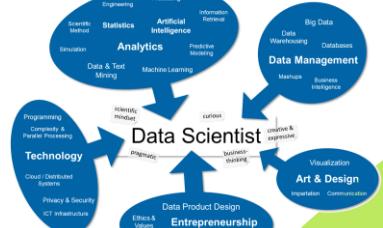
# Die nächsten 20 Minuten



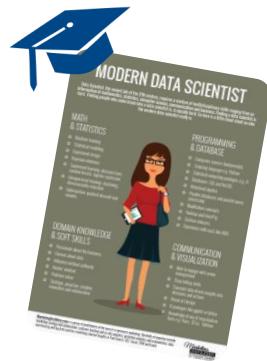
Rolle des  
PhD  
Programms

Stand der  
Forschung

Data Science  
als Motor



Ausblick



# Viele Begriffe, ein Trend: Digitalisierung

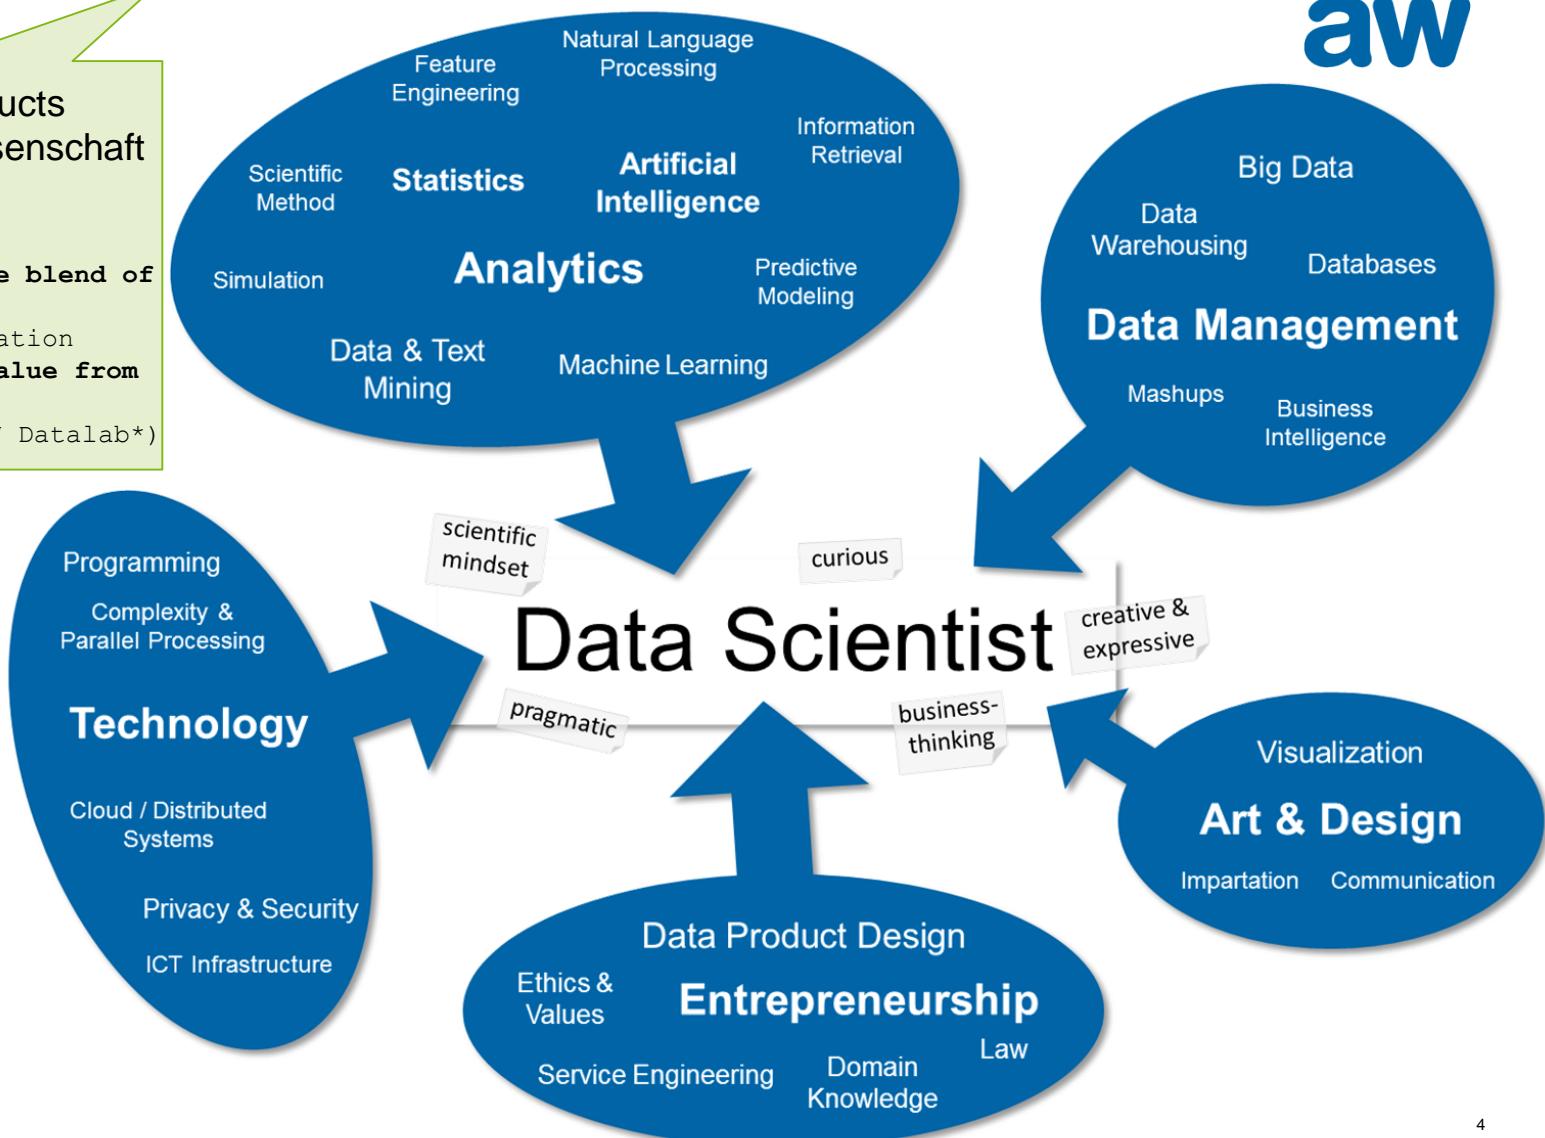
## Schlagwörter und inhaltliche Treiber



# Was ist Data Science?

Ermöglicht Data Products  
 → **Angewandte Wissenschaft**  
 → Interdisziplinär

Data Science := "Unique blend of skills from analytics, engineering & communication aiming at generating value from the data itself [...]"  
 (ZHAW Datalab\*)



# Der Stand der Forschung

## Durchbrüche allein im Bereich Deep Learning auf Big Data

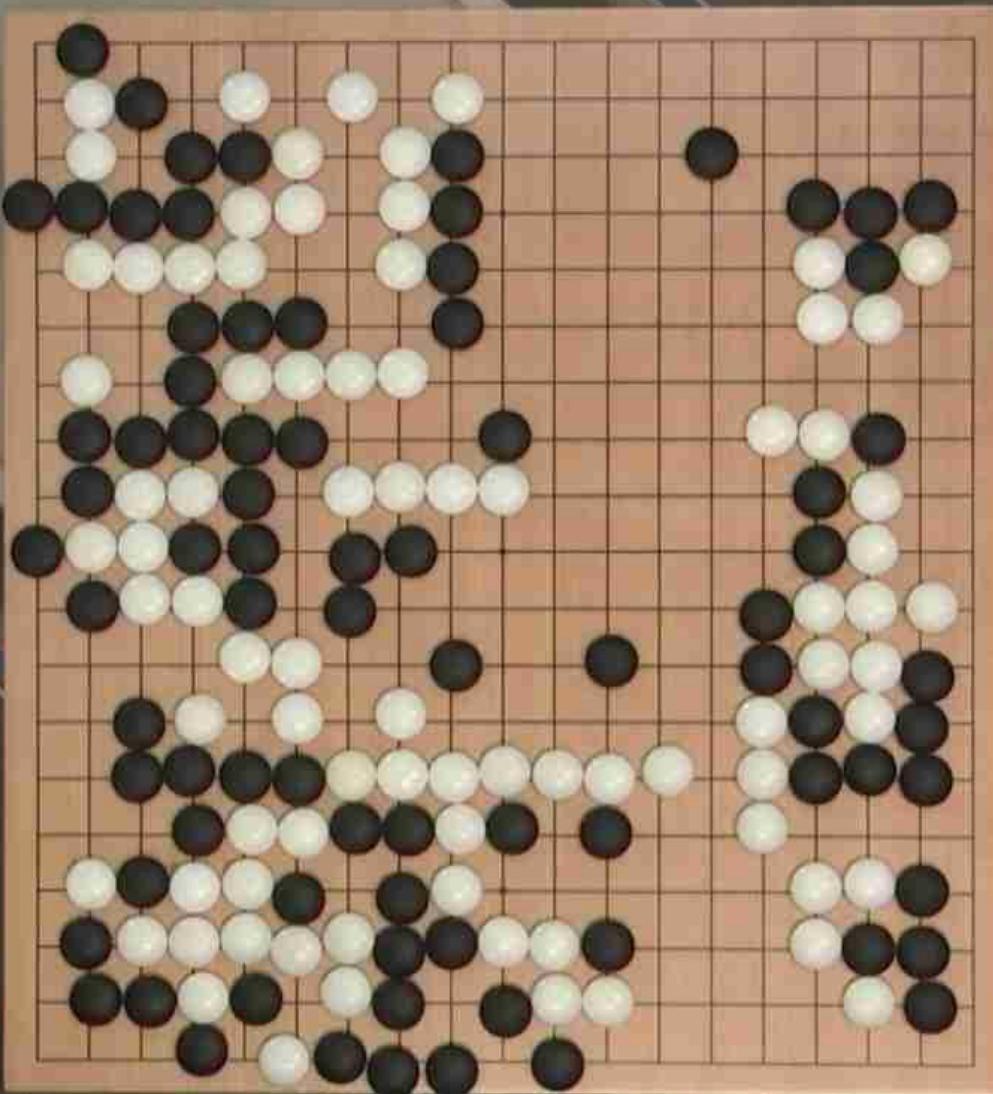
Die **letzten 18 Monate** lieferten eine beeindruckende Liste **bedeutsamer Durchbrüche** in der Automatisierung **wahrnehmungsbezogener Aufgaben**.

→ siehe die nächsten 2 Folien (weitere im Anhang)



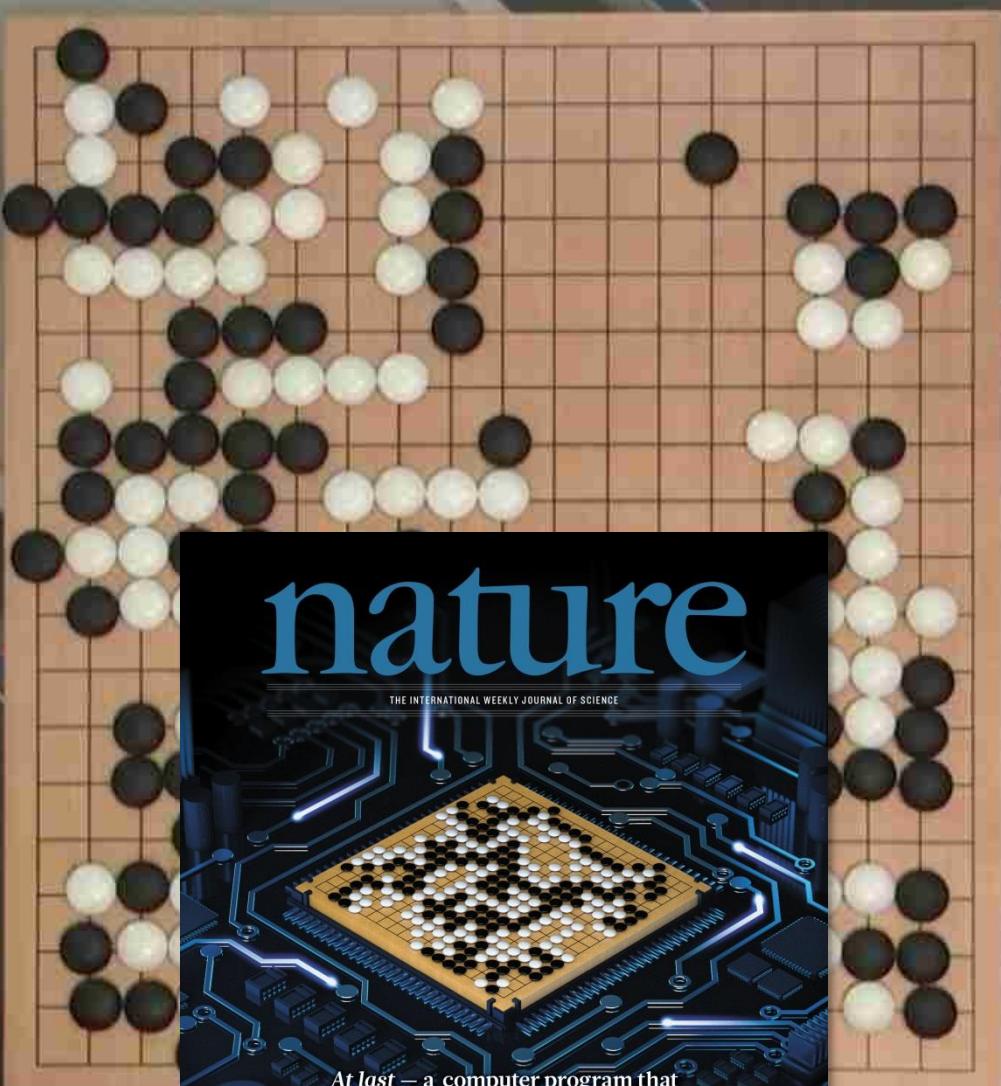


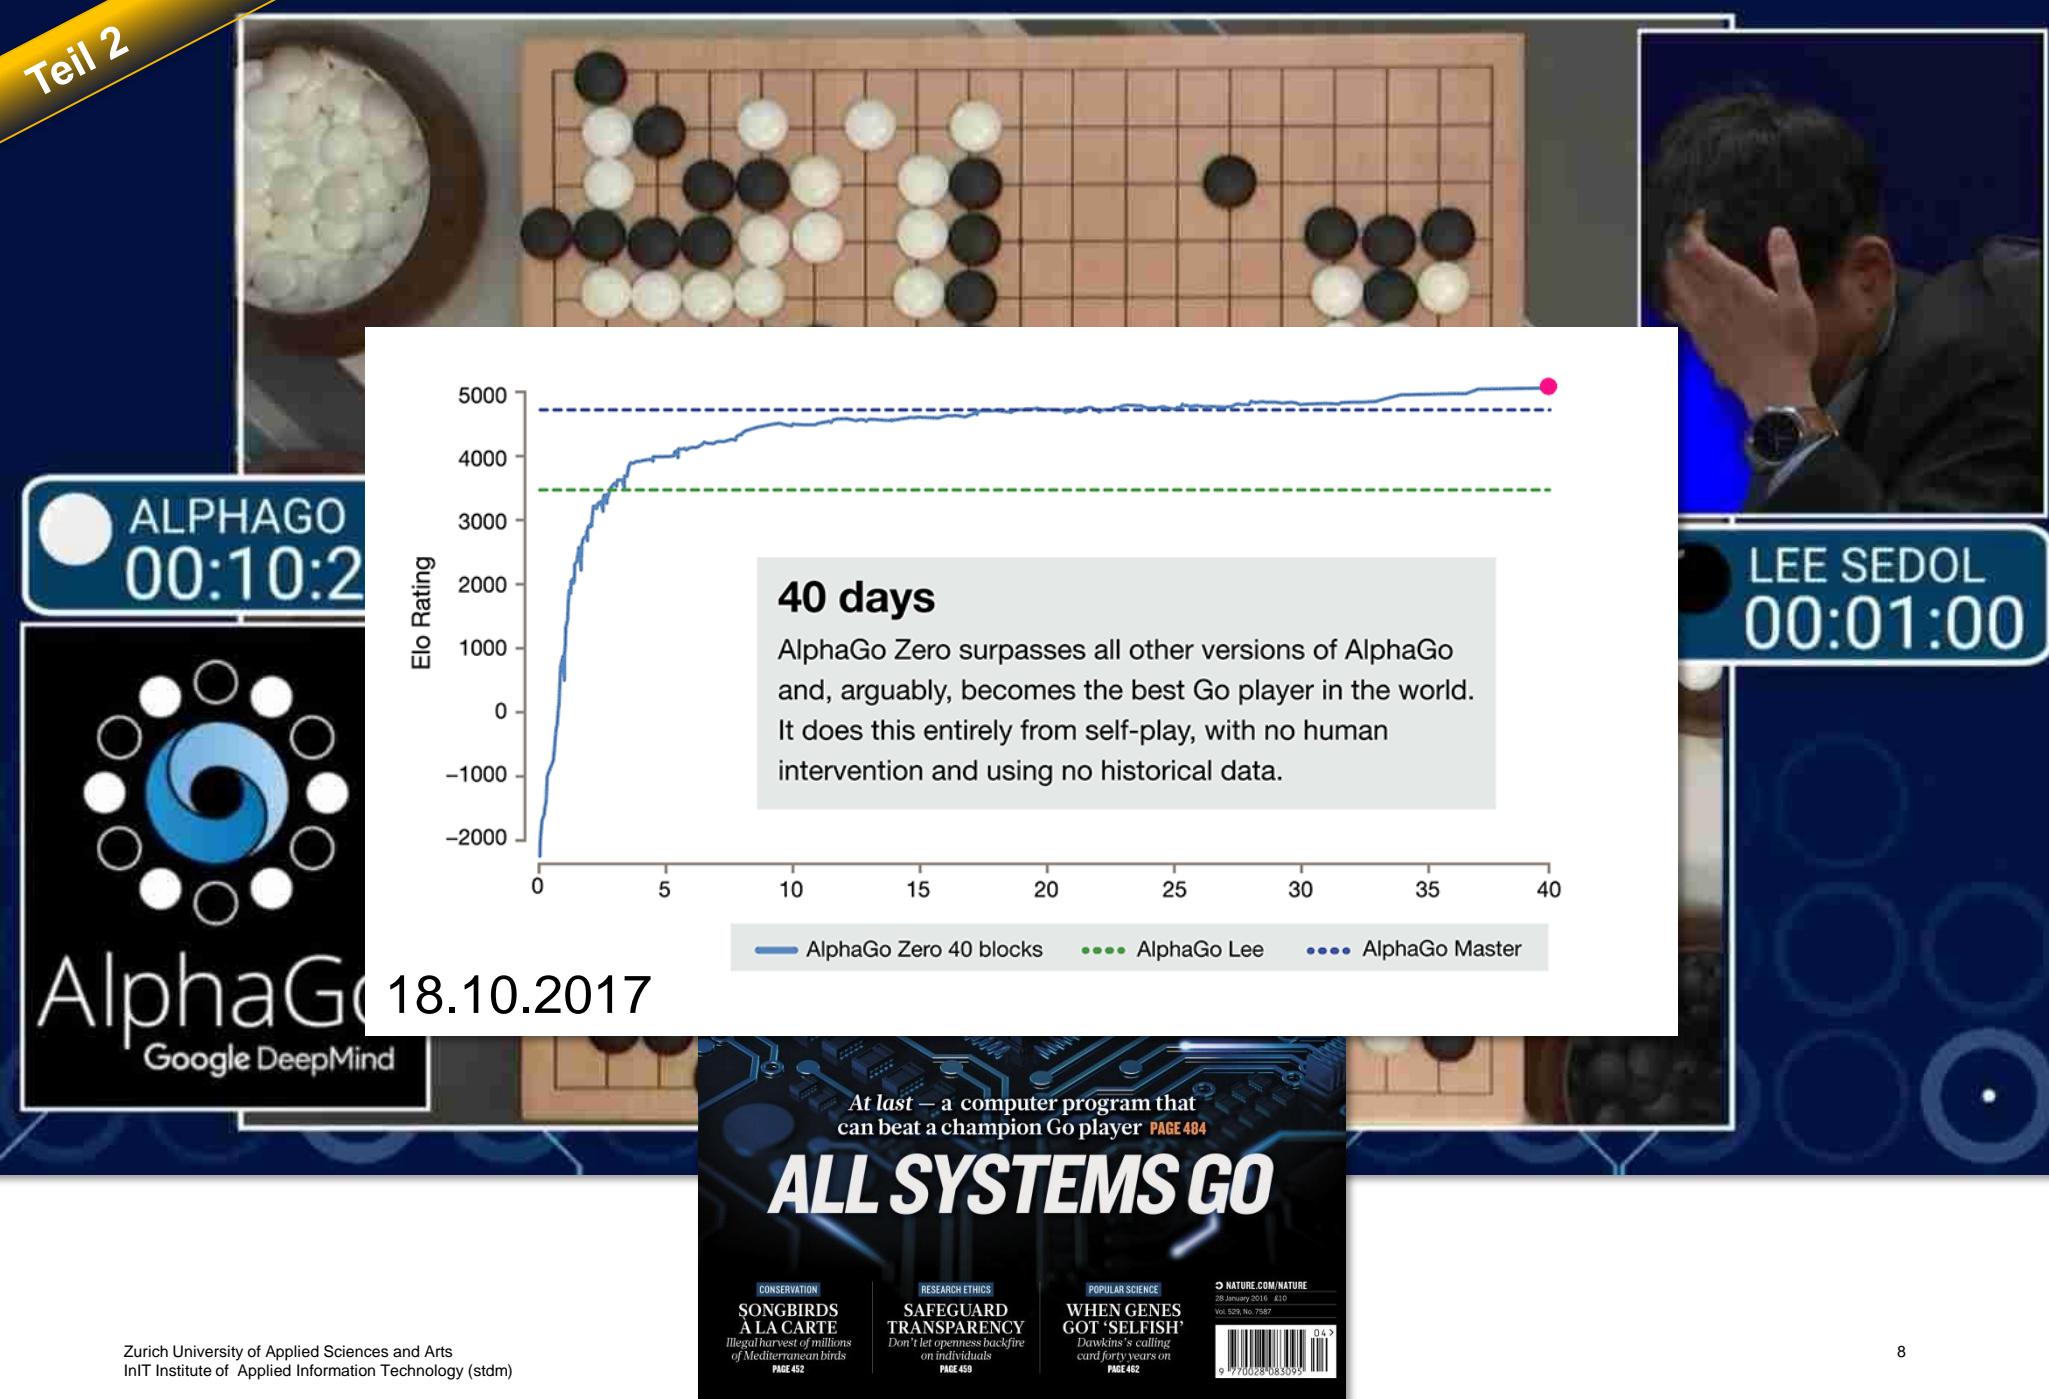
ALPHAGO  
00:10:29



LEE SEDOL  
00:01:00







# ...und viele weitere!

Brandon Amos About Blog

## Image Completion with Deep Learning in TensorFlow

August 9, 2016

- Introduction
- Step 1: Interpreting images as samples from a probability distribution
  - How would you fill in the missing information?
  - But where does statistics fit in? These are images.
  - So how can we complete images?
- Step 2: Quickly generating fake images
  - Learning to generate new samples from an unknown probability distribution
  - [ML-Heavy] Generative Adversarial Net (GAN) building blocks
  - Using  $G(z)$  to produce fake images
  - [ML-Heavy] Training DCGANs
  - Existing GANs
  - [ML-Heavy] DCGANs
  - Running DCGANs
- Step 3: Finding the right model
  - Image completion
  - [ML-Heavy] 1
  - [ML-Heavy] 2
  - [ML-Heavy] 3
  - Completing your images
- Conclusion
- Partial bibliography
- Bonus: Incomplete

### Introduction

Content-aware fill is a powerful technique for image completion and inpainting. It's great for filling in missing parts of images, but what about filling in entire images? "Semantic Image Inpainting" shows how to use deep learning to fill in some deeper portions of images. This section can be skipped if you're not interested in image completion with TensorFlow. Well approach image completion with three steps:

- We'll first interpret the image.
- This interpretation will tell us what's missing.
- Then we'll find the right model to complete the image.

Andrey Karpathy blog About Hacker's guide to Neural Networks

## The Unreasonable Effectiveness of Recurrent Neural Networks

May 21, 2015

There's something magical about Recurrent Neural Networks (RNNs). I still remember when I trained my first recurrent network for image captioning. Within a few dozen minutes of training my first baby model (with rather arbitrarily-chosen hyperparameters) started to generate very nice looking descriptions of images that were on the edge of making sense. Sometimes the ratio of how simple your model is to the quality of the results you get out of it blows past your expectations, and this was one of those times. What made this result so shocking at the time was that the common wisdom was that RNNs were supposed to be difficult to train (with more experience I've in fact reached the opposite conclusion). Fast forward about a year: I'm training RNNs all the time and I've witnessed their power and robustness many times, and yet their magical outputs still find ways of amusing me. This post is about sharing some of that magic with you.

We'll train RNNs to generate text character by character and ponder the question "how is that even possible?"

By the way, together with this post I am also releasing code on GitHub that allows you to train character-level language models based on multi-layer LSTM. You give it a large chunk of text and it will learn to generate text like it one character at a time. You can also use it to reproduce my experiments below. But we're getting ahead of ourselves; What are RNNs anyway?

### Recurrent Neural Networks

Sequences. Depending on your background you might be wondering: What makes Recurrent Networks so special? A glaring limitation of Vanilla Neural Networks (and also Convolutional Networks) is that their API is too constrained: they accept a fixed-sized vector as input (e.g. an image), and produce a fixed-sized vector as output (e.g. probabilities of different classes). Not only that: These models perform this mapping using a fixed amount of computational steps (e.g. the number of layers in the model). The core reason that recurrent nets are more exciting is that they allow us to operate over sequences of vectors. Sequences in the input, the output, or in the most general case both. A few examples may make this more concrete:

**VIOLA:**

Why, Salisbury must find his flesh and thought  
 That which I am not aps, not a man and in fire,  
 To show the reining of the raven and the wars  
 To grace my hand reproach within, and not a fair are hand,  
 That Caesar and my goodly father's world;  
 When I was heaven of presence and our fleets,  
 We spare with hours, but cut thy council I am great,  
 Murdered and by thy master's ready there  
 My power to give thee but so much as hell:  
 Some service in the noble bondman here,  
 Would show him to her wine.

**KING LEAR:**

O, if you were a feeble sight, the courtesy of your law,  
 Your sight and several breath, will wear the gods  
 With his heads, and my hands are wonder'd at the deeds,  
 So drop upon your lordship's head, and your opinion  
 Shall be against your honour.

Attributed to William Shakespeare. © 1995-2015, The Folger Shakespeare Library. All rights reserved. The Folger Shakespeare Library makes its digital resources available under the Creative Commons Attribution Non-Commercial-ShareAlike 3.0 Unported License. The Folger Shakespeare Library is a registered trademark of the Folger Institute, Inc.



## the morning paper

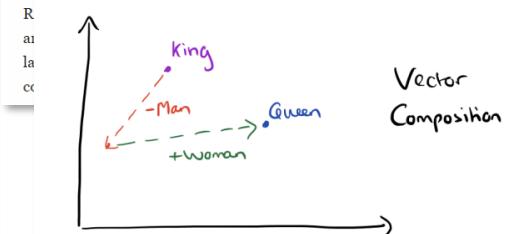
### The amazing power of word vectors

APRIL 21, 2016

For today's post, I've drawn material not just from one paper, but from five! The subject matter is 'word2vec' – the work of Mikolov et al. at Google on efficient vector representations of words (and what you can do with them). The papers are:

- ★ Efficient Estimation of Word Representations in Vector Space – Mikolov et al. 2013
- ★ Distributed Representations of Words and Phrases and their Compositionality – Mikolov et al. 2013
- ★ Linguistic Regularities in Continuous Space Word Representations – Mikolov et al. 2013
- ★ word2vec Parameter Learning Explained – Rong 2014
- ★ word2vec Explained: Deriving Mikolov et al.'s Negative Sampling Word-Embedding Method – Goldberg and Levy 2014

From the first of these papers ('Efficient estimation...') we get a description of the *Continuous Bag-of-Words* and *Continuous Skip-gram* models for learning word vectors (we'll talk about what a word vector is in a moment...). From the second paper we get more illustrations of the power of word vectors, some additional information on optimisations for the skip-gram model (hierarchical softmax and negative sampling), and a discussion of *analogies* and *metaphors* to illustrate the third paper's findings.



# ...und viele weitere!

Brandon Amos About Blog

## Image Completion with Deep Learning in TensorFlow

August 9, 2016



- Introduction
- Step 1: Interpreting images as samples from a probability distribution
  - How would you fill in the missing information?
  - But where does statistics fit in? These are images.
  - So how can we complete images?
- Step 2: Quickly generating fake images
  - Learning to generate new samples from an unknown probability distribution
  - [ML-Heavy] Generative Adversarial Net (GAN) building blocks
  - Using  $G(z)$  to produce fake images
  - [ML-Heavy] Training DCGANs
  - Existing GANs
  - [ML-Heavy] DCGANs
  - Running DCGANs
- Step 3: Finding the right samples
  - Image completion
  - [ML-Heavy] DCGANs
  - [ML-Heavy] 2D GANs
  - Completing your images
- Conclusion
- Partial bibliography
- Bonus: Incomplete

### Introduction

Content-aware fill is a powerful technique for image completion and inpainting. It's great for filling in missing parts of images, but what if you want to do content-aware fill, image completion, and inpainting all at once? That's where "Semantic Image Inpainting" comes in. This paper shows how to use deep learning to fill in missing portions of images. Some sections can be skipped if you're not interested in learning about image completion or tensorflow.

We'll approach image completion by first interpreting the image.

1. We'll first interpret the image.
2. This interpretation will help us find the missing parts.
3. Then we'll find the missing parts.



GEEK.COM

TECH

## Nvidia AI Generates Fake Faces Based On Real Celebs

BY STEPHANIE MLOT 10.21.2017 :: 10:00AM EST

32 SHARES



I'm getting a distinctly mid-90s "The Rachel" vibe from the woman in the top left corner (via Nvidia)

### STAY ON TARGET

AI Shelley Pens Truly Creepy Horror Stories—And You Can Help

Neural Network Serves Up Truly Frightening Halloween Costume Ideas

Celebrity scandals are about to get a lot more complicated.

Nvidia has developed a way of producing photo-quality, AI-generated human profiles—by using famous faces.

Andrij Karpathy blog

About Hacker's guide to Neural Networks

## The Unreasonable Effectiveness of Recurrent Neural Networks

## the morning paper

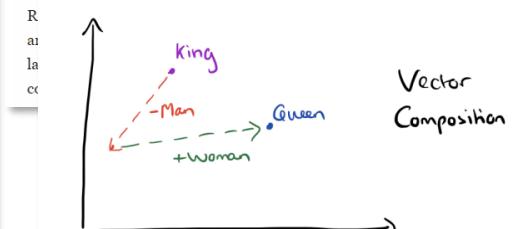
### The amazing power of word vectors

APRIL 21, 2016

For today's post, I've drawn material not just from one paper, but from five! The subject matter is 'word2vec' – the work of Mikolov et al. at Google on efficient vector representations of words (and what you can do with them). The papers are:

- ★ Efficient Estimation of Word Representations in Vector Space – Mikolov et al. 2013
- ★ Distributed Representations of Words and Phrases and their Compositionality – Mikolov et al. 2013
- ★ Linguistic Regularities in Continuous Space Word Representations – Mikolov et al. 2013
- ★ word2vec Parameter Learning Explained – Rong 2014
- ★ word2vec Explained: Deriving Mikolov et al.'s Negative Sampling Word-Embedding Method – Goldberg and Levy 2014

From the first of these papers ('Efficient estimation...') we get a description of the *Continuous Bag-of-Words* and *Continuous Skip-gram* models for learning word vectors (we'll talk about what a word vector is in a moment...). From the second paper we get more illustrations of the power of word vectors, some additional information on optimisations for the skip-gram model (hierarchical softmax and negative sampling), and a discussion of *analogies* and *metaphors*.



# ZHAW Datalab: Est. 2013



## Forerunner

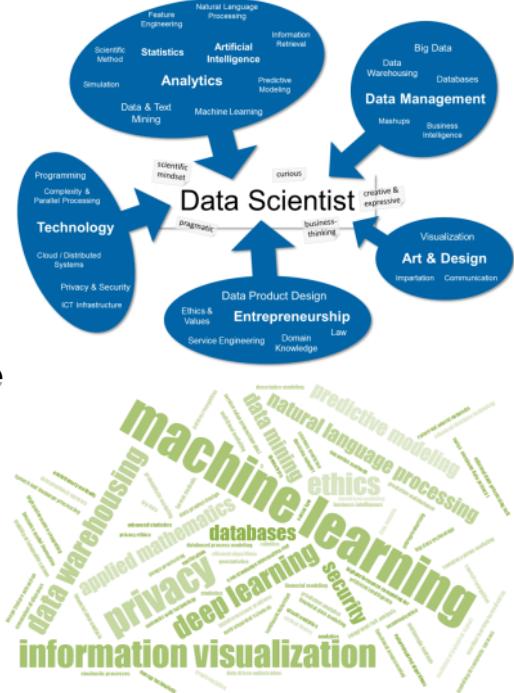
- **One of the first** interdisciplinary data science initiatives in Europe
- One of the first interdisciplinary centers at ZHAW

## Foundation

- **People:** ca. 70 researchers from 5 institutes / 3 departments opted in
- Vision: Nationally leading and internationally recognized center of excellence
- Mission: Generate projects through critical mass and mutual relationships
- Competency: Data product design with structured and unstructured data

## Success factors

- **Lean** organization and operation → geared towards projects
- Years of successful **pre-Datalab collaboration**

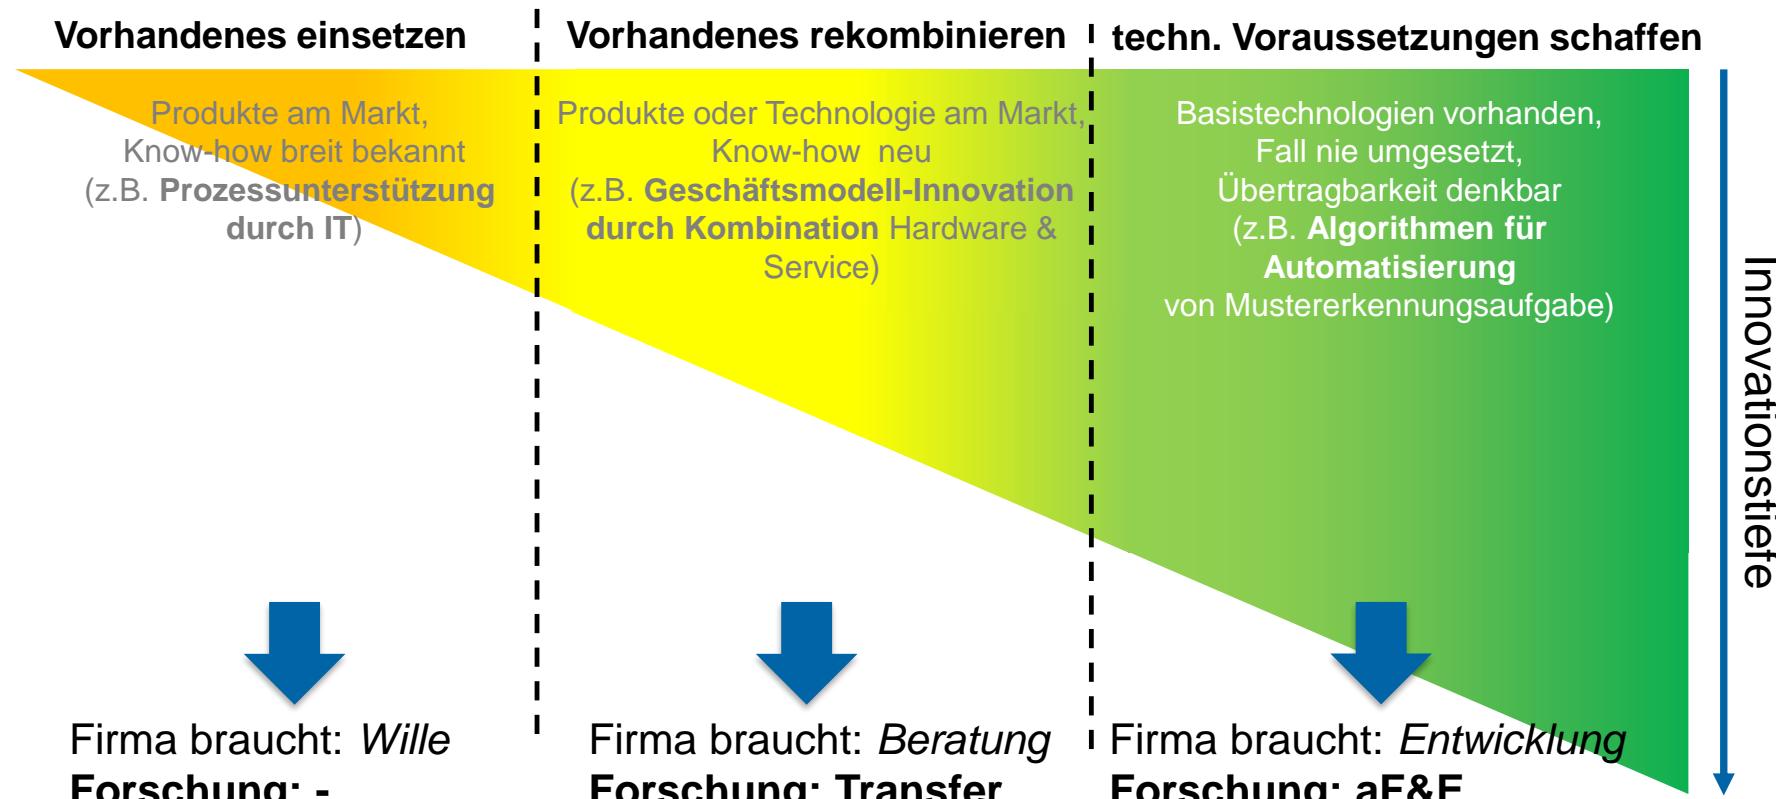


# Unsere Rolle als Forscher an Fachhochschulen

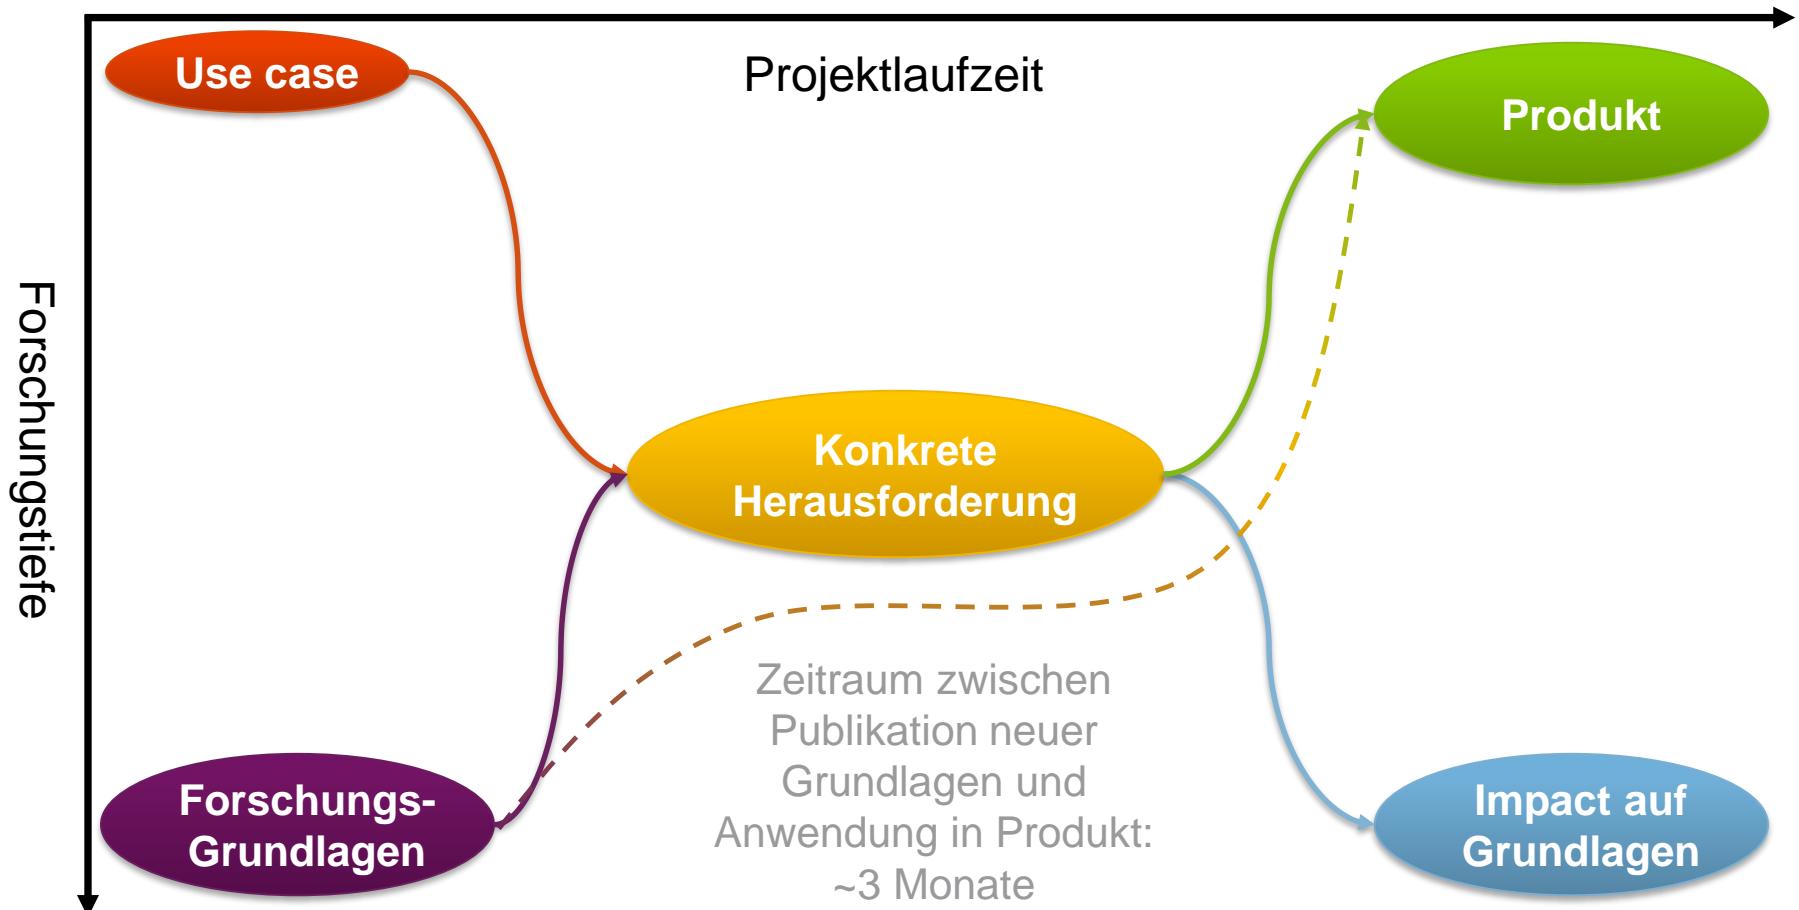
Innovation in Zeiten der Digitalisierung → siehe Konferenz Digitale Schweiz



## 3 Arten von betrieblicher Innovation in der Digitalisierung



# Parallelität von Grundlagen- und aF&E Innovation in Zeiten der Digitalisierung, contd.



# Angewandte F&E im ZHAW Datalab

## Fünf Beispiele

- **Produktionsautomatisierung** für KMU mit *Deep Neural Networks*
- **Intuitive Suche** in Datenbanken für Bioinformatiker mit *Big Data Technologie*
- **Behandlungsplanung** für Aneurysmen mit *Maschinellem Lernen*
- **Energieoptimale Gebäudesteuerung** mit *Simulation* und *Model Predictive Control*
- **Automatische Agenten** in Computerspielen mit *Reinforcement Learning*
- (zwei weitere: siehe Anhang)



## Overview

### Partners

Who are we

- ARGUS der Presse AG**
  - Switzerland's leading media monitoring and information provider
  - Experience of more than 100 years

- ZHAW Datalab**
  - Interdisciplinary research group at Zurich University of Applied Sciences
  - Combining the knowledge of different fields related to machine learning

### The Project

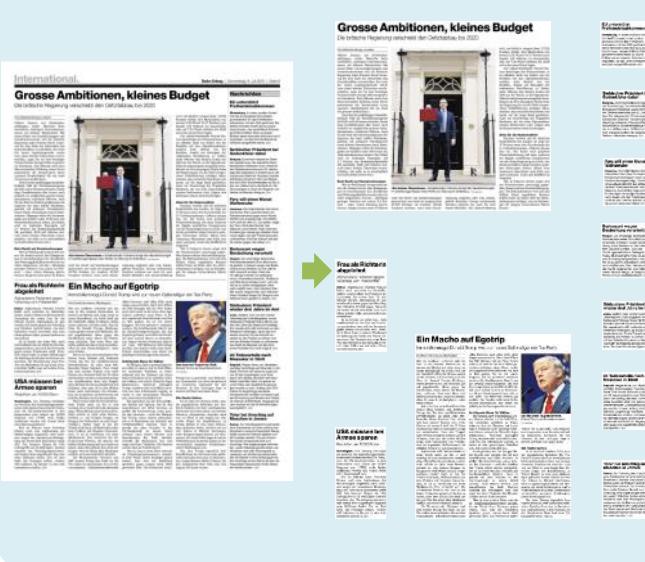
What do we do

#### Goal

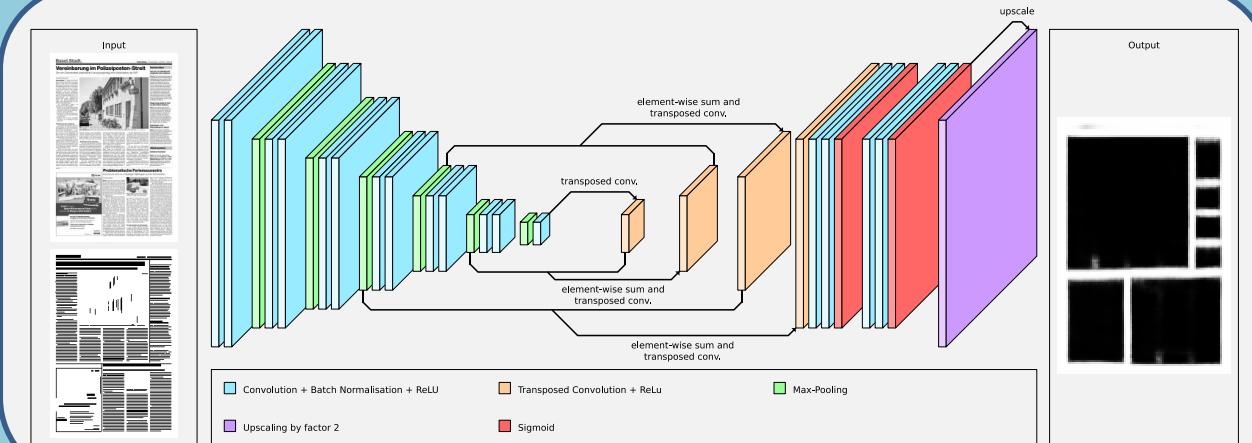
- Real Time Print Media Monitoring
  - Extraction of relevant articles from newspaper pages
  - Delivering articles to customers

#### Problem

- Fully automated article segmentation
- Identification of article elements (e.g. title, subtitle, etc.)

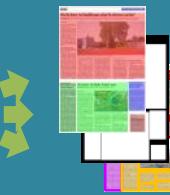


## Most Successful Approach [3]



### Combination

Combination of rules, visual and textual features



## Result

### References

- [1] D. Ciresan, A. Giusti, L. M. Gambardella, and J. Schmidhuber. Deep neural networks segment neuronal membranes in electron microscopy images. In NIPS, pages 2852–2860, 2012.
- [2] T. Mikolov, K. Chen, G. Corrado, and J. Dean. Efficient Estimation of Word Representations in Vector Space. In Proceedings of Workshop at ICLR, 2013.
- [3] B. Meyer, T. Stadelmann, J. Stampfli, M. Arnold, M. Cieliebak. Fully Convolutional Neural Networks for Newspaper Article Segmentation. In Proceedings of ICDAR, Kyoto, Japan, 2018.

# Bio-SODA: Enabling Complex, Semantic Queries to Bioinformatics Databases through Intuitive Searching over Data

## Intuitive exploration

- ✓ without knowing SPARQL, SQL, etc
- ✓ without knowing database schemas
- ✓ large datasets

## Impact

- large bioinformatics user bases
- future federation of life sciences

Lead: Kurt Stockinger, ZHAW



**Big Data**  
Nationales Forschungsprogramm



FONDS NATIONAL SUISSE  
SCHWEIZERISCHER NATIONALFONDS  
FONDO NAZIONALE SVIZZERO  
SWISS NATIONAL SCIENCE FOUNDATION

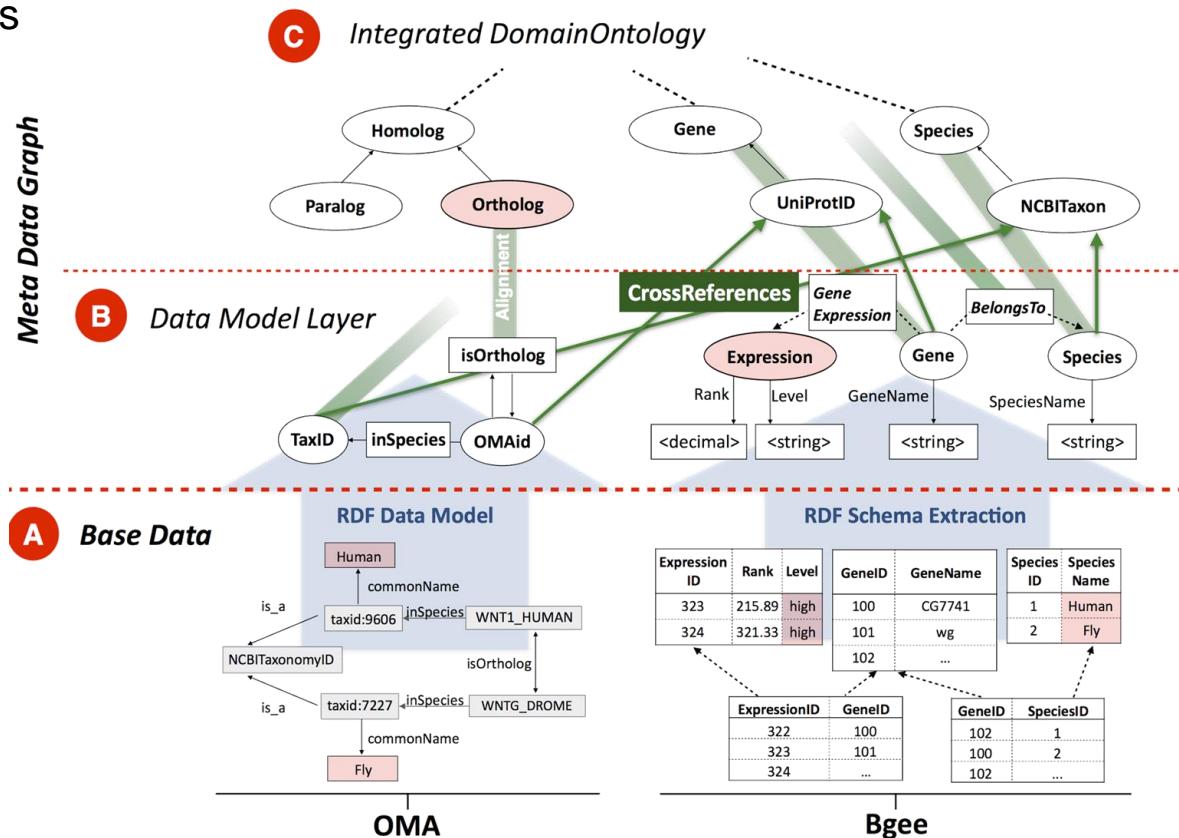
Zürcher Fachhochschule



*Unil*  
UNIL | Université de Lausanne



Swiss Institute of  
Bioinformatics

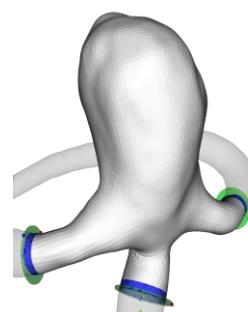


# AneuX: Ist die Form signifikant für die Gefährdung eines Aneurysmas?

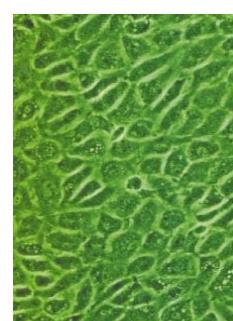
Aneurysm im Röntgenbild (XA)



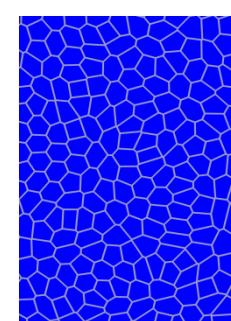
Isoliertes Aneurysma  
Zur Formanalyse



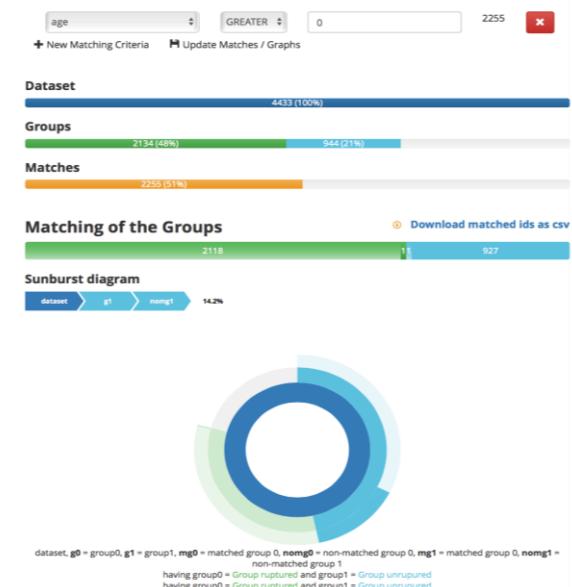
Zellen der Gefäßwand



Modell der Gefäßwand



Webtool für statistische Analyse



SystemsX.ch funding: 2M CHF, Begutachtung SNSF

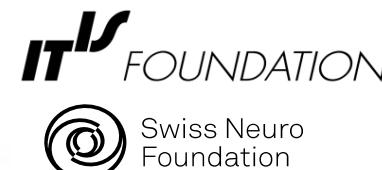
- Morphologische Analyse von Aneurysmen mit Machine Learning
- Biologisch motiviertes Simulationsmodell für Zellwandveränderung
- Aufbau eines Krankheitsmodells für die Behandlungsplanung
- Aufbau einer Datenbank von Aneurysmen
- Erstellung von Werkzeuge zur Analyse der klinischen Daten und Bilddaten

Partner (Co-Antragsteller Sven Hirsch, ZHAW):

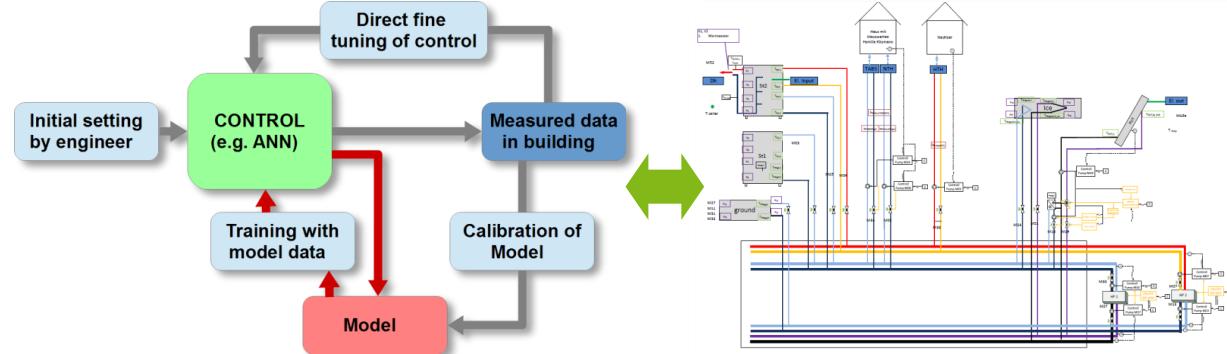
Zürcher Fachhochschule



AneuX  
Shape as Biomarker  
for Aneurysm Disease



# Hydrobus: Simulation-based Optimization



**SCHAFFHAUSER BAUER** 2

**DONNERSTAG, 30. JUNI 2016, NUMMER 25**

NACHGEMERGT

«Faszinierend!»

Auch Hansueli Gröb hat die Pflasterlage Sonnegg in Gossau bedient. Das Schaffhauser Unternehmen hat einen weiteren Betrieb übernommen und dort entsprechend geplant. Eigentlich hierarchisch der thermische Speicher, der im Dach untergebracht ist, befindet sich in einem Bereich der Espeicher. Dieser befindet sich in einem Abwasserweiter aus der Gemeinde Gossau. Ein Wasserrohr verzweigt sich ab und wird mit 170 m<sup>2</sup> Regenwasser gefüllt. Im Wasser kann der gesammelte Wasserdurchfluss ausgenutzt werden, während es gefiltert wird.

Wasser-Wasser für die Lippische entströmt aus dem Verteiler zum Haus. Die Umgebung ist geprägt durch die Landschaft und damit durch die Forstwirtschaft. Das ganze Jahr über kann der Wasserdurchfluss von der Espeicher-Sonne mittels Energie der Sonnenstrahlung aufgewärmt werden. Ein Wasserrohr verzweigt sich am Ende des Abwasserweiters und fließt in das Regenwasserbecken. An dem Dach unter den Espeichern kommt die Sonnenenergie optimal zur Geltung.

Am 15. April 2016 wurde die Pflasterlage Sonnegg offiziell eingeweiht. Am 16. April 2016 wurde der Betrieb aufgenommen. Am 17. Mai 2016, Letzte Woche wurde die neue Pflasterlage Sonnegg in Gossau im Rahmen des Pflasterprojekt Sonnegg in Gossau eingeweiht.

Das ehemalige Beizhaus ist neuweig ausgeplattiert und energetisch optimiert. Der im ehemaligen Beizhaus befindende Komplex neben zwei Wohnungen im Rino-Haus soll ab Sommer 2016 in Arbeit gehen. Im Erdgeschoss wird ein kleiner Sitzplatz für den öffentlichen Nahverkehr eingerichtet. In einem Raum befindet sich ein kleiner Busbahnhof mit seinen Firmen Rino Electronics AG und Geoterm.

Rino Rittmann (r.) erläutert die komplexe Verarbeitung der verschiedenen Prozesse am Spezialthermometer. (G. Stähler, GE-Archiv des Projekts)

**Offizielles Organ des Schweizerischen Bauernverbandes und seiner Fachverbände**

**PFLASTERPROJECT**

**Kreativität und Erfindergeist sind seine Markenzeichen**

**Hansueli Gröb** hat die Pflasterlage Sonnegg in Gossau bedient. Das Schaffhauser Unternehmen hat einen weiteren Betrieb übernommen und dort entsprechend geplant. Eigentlich hierarchisch der thermische Speicher, der im Dach untergebracht ist, befindet sich in einem Abwasserweiter aus der Gemeinde Gossau. Ein Wasserrohr verzweigt sich ab und wird mit 170 m<sup>2</sup> Regenwasser gefüllt. Im Wasser kann der gesammelte Wasserdurchfluss ausgenutzt werden, während es gefiltert wird.

Wasser-Wasser für die Lippische entströmt aus dem Verteiler zum Haus. Die Umgebung ist geprägt durch die Landschaft und damit durch die Forstwirtschaft. Das ganze Jahr über kann der Wasserdurchfluss von der Espeicher-Sonne mittels Energie der Sonnenstrahlung aufgewärmt werden. Ein Wasserrohr verzweigt sich am Ende des Abwasserweiters und fließt in das Regenwasserbecken. An dem Dach unter den Espeichern kommt die Sonnenenergie optimal zur Geltung.

Am 15. April 2016 wurde die Pflasterlage Sonnegg offiziell eingeweiht. Am 16. April 2016 wurde der Betrieb aufgenommen. Am 17. Mai 2016, Letzte Woche wurde die neue Pflasterlage Sonnegg in Gossau im Rahmen des Pflasterprojekt Sonnegg in Gossau eingeweiht.

Das ehemalige Beizhaus ist neuweig ausgeplattiert und energetisch optimiert. Der im ehemaligen Beizhaus befindende Komplex neben zwei Wohnungen im Rino-Haus soll ab Sommer 2016 in Arbeit gehen. Im Erdgeschoss wird ein kleiner Sitzplatz für den öffentlichen Nahverkehr eingerichtet. In einem Raum befindet sich ein kleiner Busbahnhof mit seinen Firmen Rino Electronics AG und Geoterm.

Rino Rittmann (r.) erläutert die komplexe Verarbeitung der verschiedenen Prozesse am Spezialthermometer. (G. Stähler, GE-Archiv des Projekts)

**NACHGEMERGT**

**«Faszinierend!»**

Auch Hansueli Gröb hat die Pflasterlage Sonnegg in Gossau bedient. Das Schaffhauser Unternehmen hat einen weiteren Betrieb übernommen und dort entsprechend geplant. Eigentlich hierarchisch der thermische Speicher, der im Dach untergebracht ist, befindet sich in einem Abwasserweiter aus der Gemeinde Gossau. Ein Wasserrohr verzweigt sich ab und wird mit 170 m<sup>2</sup> Regenwasser gefüllt. Im Wasser kann der gesammelte Wasserdurchfluss ausgenutzt werden, während es gefiltert wird.

Wasser-Wasser für die Lippische entströmt aus dem Verteiler zum Haus. Die Umgebung ist geprägt durch die Landschaft und damit durch die Forstwirtschaft. Das ganze Jahr über kann der Wasserdurchfluss von der Espeicher-Sonne mittels Energie der Sonnenstrahlung aufgewärmt werden. Ein Wasserrohr verzweigt sich am Ende des Abwasserweiters und fließt in das Regenwasserbecken. An dem Dach unter den Espeichern kommt die Sonnenenergie optimal zur Geltung.

Am 15. April 2016 wurde die Pflasterlage Sonnegg offiziell eingeweiht. Am 16. April 2016 wurde der Betrieb aufgenommen. Am 17. Mai 2016, Letzte Woche wurde die neue Pflasterlage Sonnegg in Gossau im Rahmen des Pflasterprojekt Sonnegg in Gossau eingeweiht.

Das ehemalige Beizhaus ist neuweig ausgeplattiert und energetisch optimiert. Der im ehemaligen Beizhaus befindende Komplex neben zwei Wohnungen im Rino-Haus soll ab Sommer 2016 in Arbeit gehen. Im Erdgeschoss wird ein kleiner Sitzplatz für den öffentlichen Nahverkehr eingerichtet. In einem Raum befindet sich ein kleiner Busbahnhof mit seinen Firmen Rino Electronics AG und Geoterm.

Rino Rittmann (r.) erläutert die komplexe Verarbeitung der verschiedenen Prozesse am Spezialthermometer. (G. Stähler, GE-Archiv des Projekts)

## The challenge

- Not enough training data for AI in socio-technological systems

## The project

- **Self-adaption** of control to time-varying demands in a multi-apartment building using simulations
- Combined entropy and **energy optimization** of HVAC-system based on **Model Predictive Control**
- Integrates **renewable energy technology**, social dynamics and scenario-based weather prediction

## The upside

- Enables a **Swiss SME** to harvest results from **modern mathematics, data science and AI**
- Gives **science** the opportunity to **test modern approaches on real-world problems**



# Schlussfolgerungen

Welche Rahmenbedingungen benötigen wir, um erfolgreich zu bleiben?

Drei Thesen

- Digitale Innovationen laufen in **extrem kurzen** Zyklen ab
- **Einfachere** digitale **Innovationen** bestehen in der neuartigen **Kombination** von vorhandenen **Technologien** mit einem geeigneten Prozess- und **Businessmodell**
- **Komplexere** digitale Innovationen verlangen eine **Gleichzeitigkeit** von **Grundlagenforschung**, **angewandter Forschung** und **Umsetzung**

Zwei Schlussfolgerungen

- ➔ Die besten **Forschungsideen beweisen sich am Markt** in der Anwendung
- ➔ Grundlagen und anwendungsorientierte **Forschung** verlaufen **verzahnt parallel** anstatt sequentiell

## MODERN DATA SCIENTIST

Data Scientist, the sexiest job of the 21th century, requires a mixture of multidisciplinary skills ranging from an intersection of mathematics, statistics, computer science, communication and business. Finding a data scientist is hard. Finding people who understand who a data scientist is, is equally hard. So here is a little cheat sheet on who the modern data scientist really is.

**MATH & STATISTICS**

- ★ Machine learning
- ★ Statistical modeling
- ★ Experiment design
- ★ Bayesian inference
- ★ Supervised learning: decision trees, random forests, logistic regression
- ★ Unsupervised learning: clustering, dimensionality reduction
- ★ Optimization: gradient descent and variants



**PROGRAMMING & DATABASE**

- ★ Computer science fundamentals
- ★ Scripting language e.g. Python
- ★ Statistical computing packages, e.g., R
- ★ Databases: SQL and NoSQL
- ★ Relational algebra
- ★ Parallel databases and parallel query processing
- ★ MapReduce concepts
- ★ Hadoop and Hive/Pig
- ★ Custom reducers
- ★ Experience with xaaS like AWS

**DOMAIN KNOWLEDGE & SOFT SKILLS**

- ★ Passionate about the business
- ★ Curious about data
- ★ Influence without authority
- ★ Hacker mindset
- ★ Problem solver
- ★ Strategic, proactive, creative, innovative and collaborative



**COMMUNICATION & VISUALIZATION**

- ★ Able to engage with senior management
- ★ Story telling skills
- ★ Translate data-driven insights into decisions and actions
- ★ Visual art design
- ★ R packages like ggplot or lattice
- ★ Knowledge of any visualization tools e.g. Flare, D3.js, Tableau

MarketingDistillery.com is a group of practitioners in the area of e-commerce marketing. Our fields of expertise include: marketing strategy and optimization: customer tracking and on site analytics; predictive analytics and econometrics; data warehousing and big data systems; marketing channel insights in Paid Search, SEO, Social, CRM and brand.

